Regresión Lineal Simple

Equipo X

07 April, 2023

Contents

1 Introducción

1.1 Problema de interés: Análisis del precio de los vehículos

1.1.1 Breve explicación de la base de datos "Scrap price"

1.2 ¿Por qué usar una regresión lineal?

2 Marco teórico

2.1 Conceptos básicos

2.2 Supuestos del modelo

2.3 Método de selección de variables y limitaciones del modelo

3 Análisis exploratorio de datos

3.1 Análisis de la base de datos

Aquí va filtros aplicados, estadígrafos, gráficas, limpieza y selección de variable depen- diente con justificación

3.2 Selección de la variable explicativa

Para la selección de la variable explicativa eliminamos las variables de caracter, y dejamos las variables numéricas. Dividimos las variables en 3 grupos para poder analizar la correlación de las variables respecto el precio:

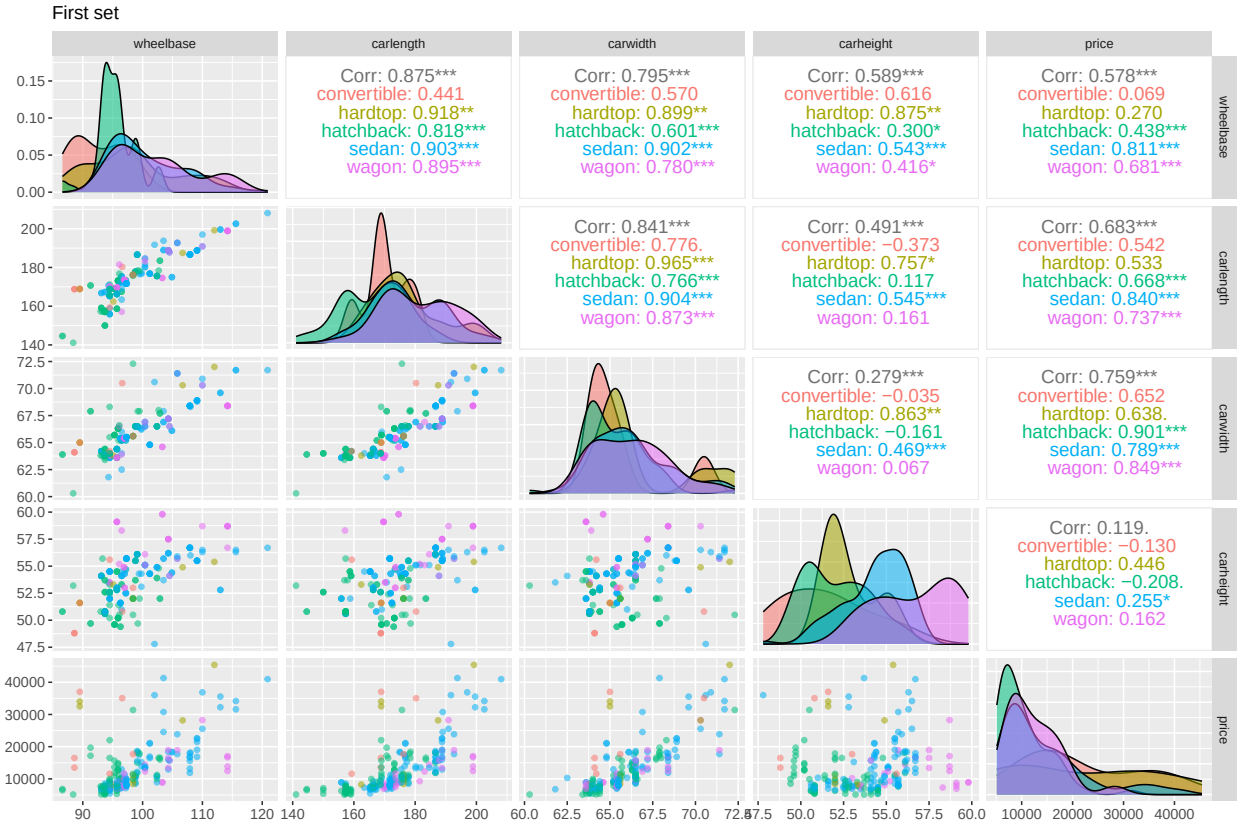

Second set

Third set

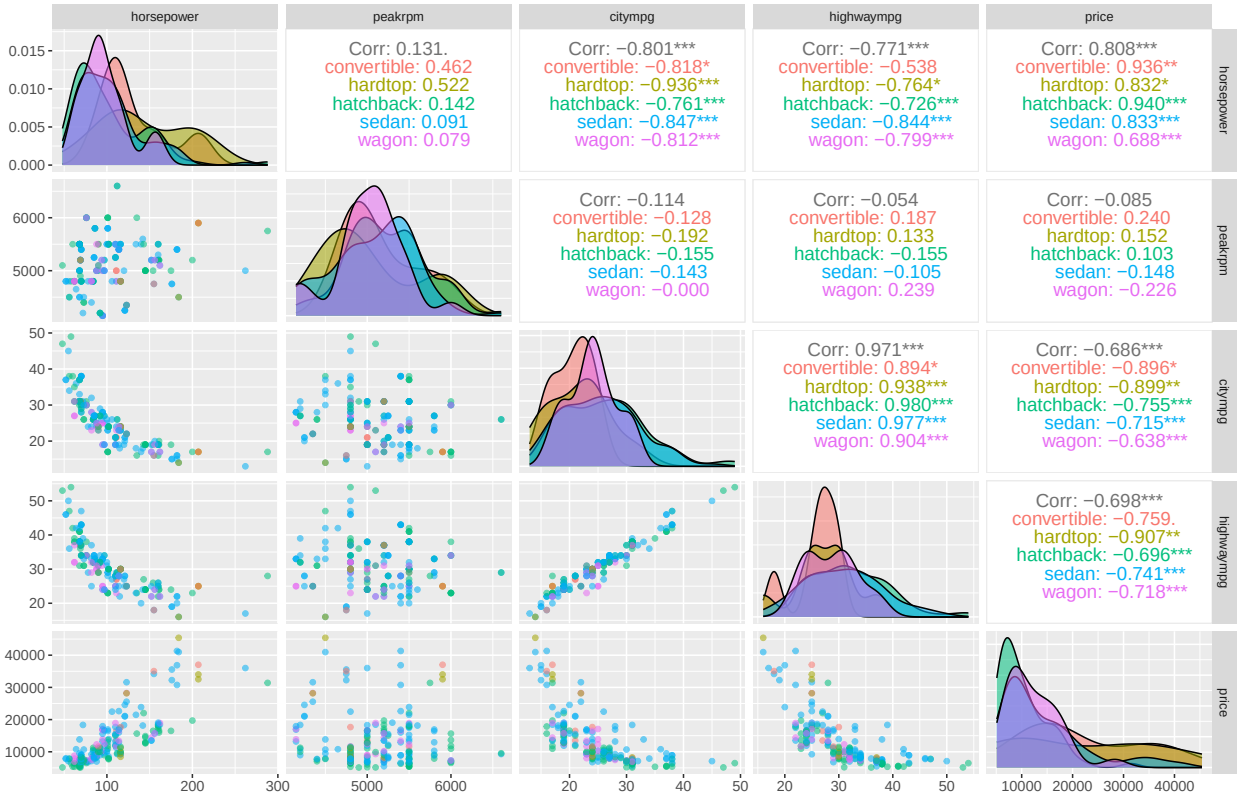

Cómo se puede observar las variables con las correlaciones más altas son:

Horsepower, curbweight, enginesize con 0.808, 0.835 y 0.874 respectivamente. No obstante, la variable que más sentido hace para elegir para explicar el motor es “enginesize”, ya que además de tener la correlación más alta respecto al precio, podemos eliminar “horse power” porque tiene una multicolienalidad imperfecta de 0.810 con la variable que elegimos.

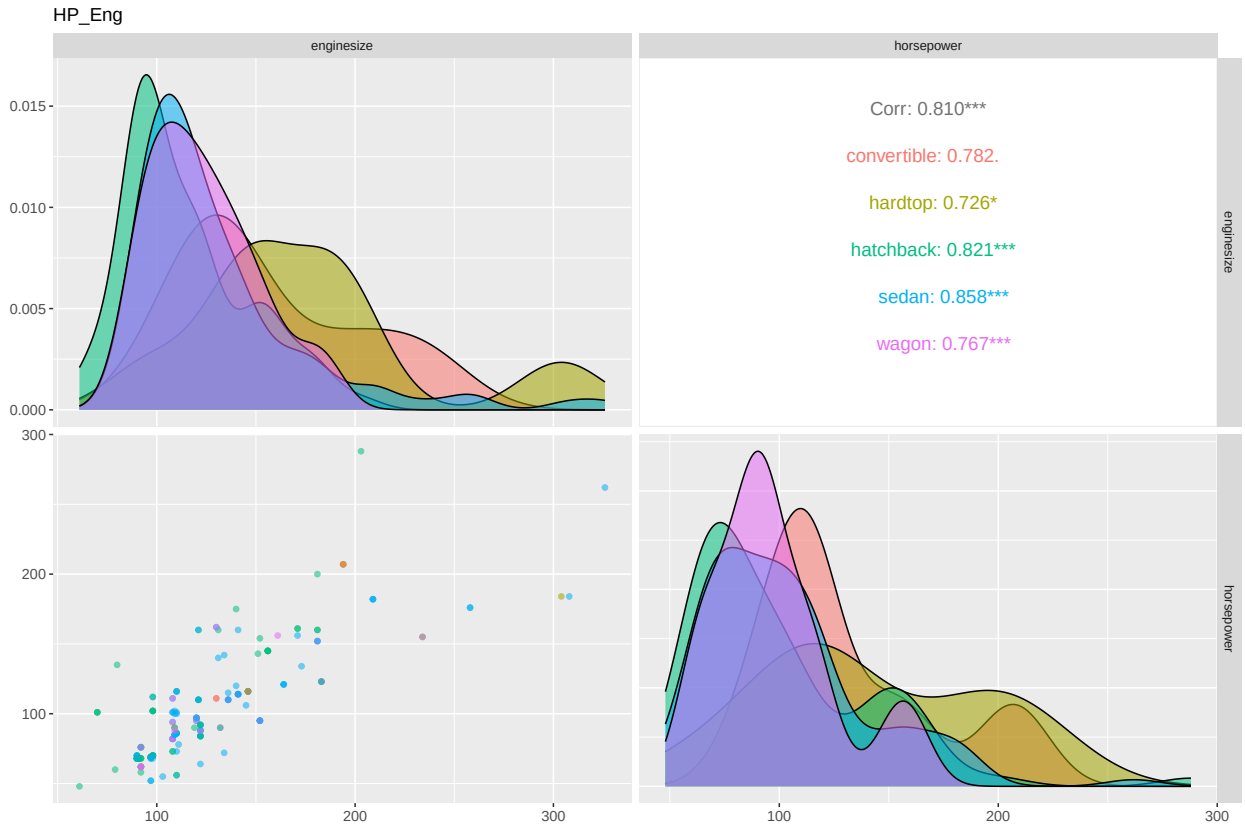

4 Modelo de regresión lineal simple

4.1 Parámetros del modelo

```
Call:
lm(formula = price ~ enginesize, data = train.base)

Residuals:
     Min       1Q   Median       3Q      Max
-10487.4  -2314.5   -566.6   1664.7  14439.1

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -8156.662   1022.821  -7.975 4.59e-13 ***
enginesize    167.620      7.497  22.359  < 2e-16 ***
---
Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1

Residual standard error: 4024 on 142 degrees of freedom
Multiple R-squared:  0.7788,    Adjusted R-squared:  0.7772
F-statistic: 499.9 on 1 and 142 DF,  p-value: < 2.2e-16
```

Podemos observar que para B0 y B1 el P value $<$ |t value | por lo tanto B0 y B1 son significativas con un nivel de confianza de 1

Tabla ANOVA

```
Analysis of Variance Table

Response: price
            Df     Sum Sq    Mean Sq F value    Pr(>F)
enginesize   1 8096361095 8096361095  499.94 < 2.2e-16 ***
Residuals  142 2299624940   16194542
---
Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1
```

4.2 Análisis de residuales

4.2.1 Comprobación de la linealidad de la Fn de regresión

Comprobamos con la R^2, en este caso los errores se acercan un 77% a nuestra recta de regresión lo que nos dice que sí hay linealidad en ella, lo comprobamos sacando la R^2

nos da el .7787968 de R^2

4.2.2 Heterocedasticidad

Comprobamos heterocedisticidad (la varianza de los errores es constante), lo comprobamos con un gráfico comparando los residuales con las Y observadas ($\hat{y}$), para esto tenemos que hacer un DF con ambos vectores obtenidos de nuestro modelo

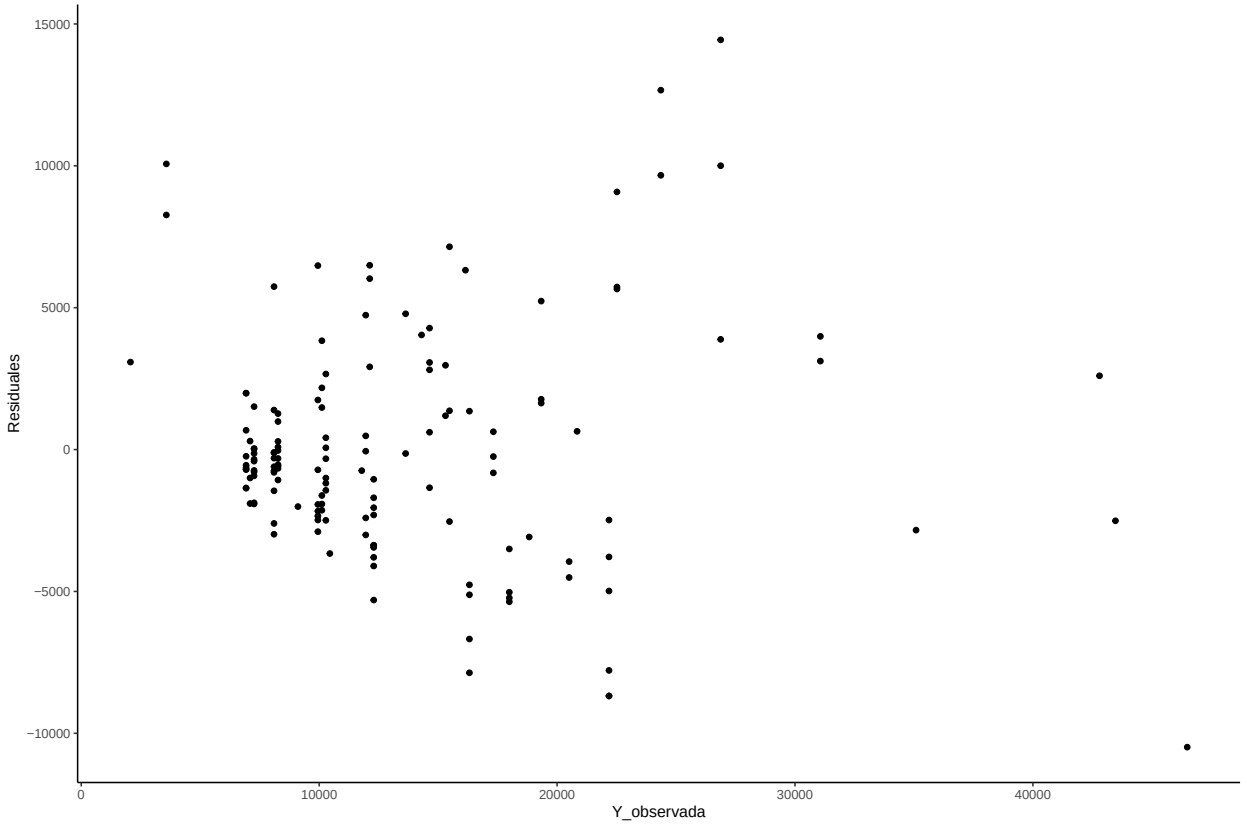

Se puede observar que no hay un patrón en sí en el gráfico, como una recta, con esto podemos asumir que hay heterocedisticidad.

4.2.3 Independencia en los errores

No es una serie de tiempo - no aplica ya que los datos no llevan un orden y pueden cambiar de pocisión

4.2.4 Presencia de errores atípicos

Esto se hace calculando la raíz de el cuadrado medio de la suma de cuadrados de los errores (MSE), el cual se obtiene de la tabala ANOVA de nuestros residuales el mean.

Ya con MSEˆ(1/2), podemos sacar la división de los residuales entre la raíz de MSE y compararlos con xi esas variables las metemos en un DF y graficamos las diferencias.

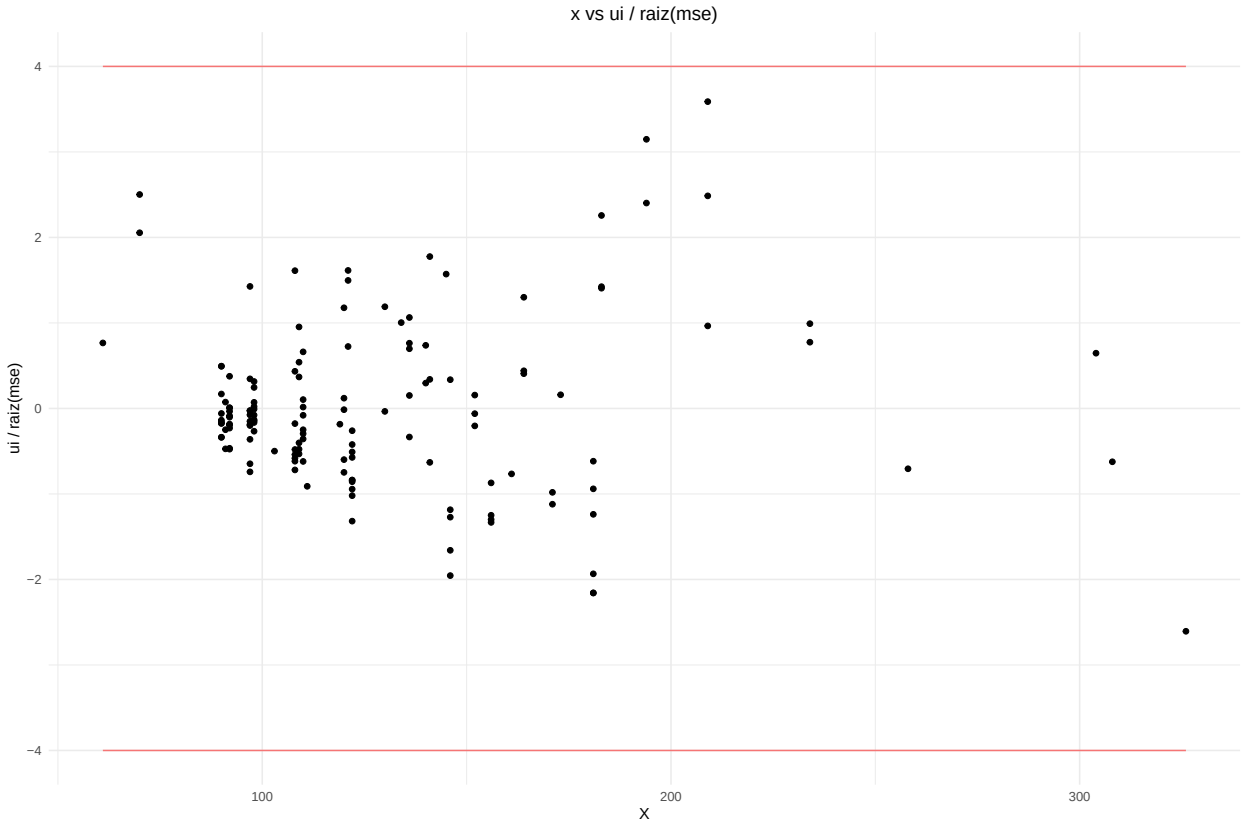

4.2.5 Verificar la normalidad en los errores

La QQ plot - esa se hace con los residuales sacamos los residuales de nuestro modelo

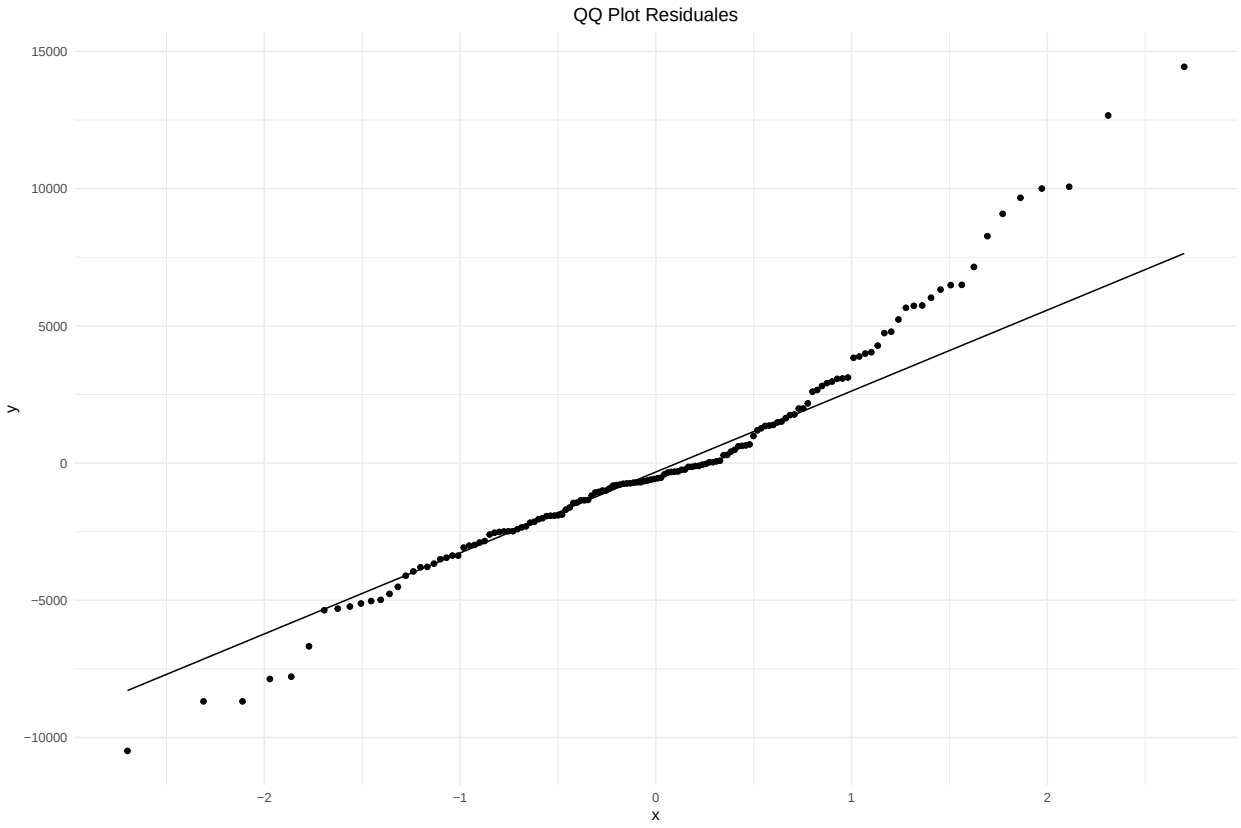

Rechazamos el supuesto de normalidad de los errores debido a las dos colas que muestra el gráfico de QQ plot. No obstante, ya que el modelo de regresión lineal simple ajustado es robusto ante el supuesto de normalidad podemos continuar usando esta variable explicativa.

4.3 Intervalo de confianza y predicción al 95%

Sacamos el intervalo de confianza de E[Y], esto lo hacemos para ver el intervalo en donde van a estar las siguientes E[Y / X], independientemente de la muestra.

En R usamos la fn Predict.lm la alimentamos con el modelo_1 con nuestra data de entrenamiento aplicando el intervalo de confianza a el nivel requerido, en este caso .95 [Explicar porque]